

Señales visuales, estimación de demanda y diseño de mecanismos en la asignación de cupos escolares de Bogotá

Bautista, D. Fuentes, J. Melo, J.

2026

1. Introducción

El sistema de educación pública de Bogotá agrupa 413 instituciones en 740 sedes distribuidas en 20 localidades (SED, 2023). La demanda oficial muestra contracción sostenida ($-1,2$ % anual 2019–2023), pero las localidades de menor ingreso — Kennedy, Bosa, Ciudad Bolívar — concentran más del 40 % de los cupos nuevos solicitados.

La asignación de cupos está regulada por la SED (2025) mediante un índice de priorización que combina condición socioeconómica (SISBEN) y proximidad geográfica, formalizable como DA (Gale y Shapley, 1962) con prioridad lexicográfica. Sin embargo, el mecanismo opera sobre preferencias que pueden estar sistemáticamente sesgadas: la literatura muestra que las familias de menores ingresos son más sensibles a señales no académicas al elegir colegio (Hastings et al., 2009), y la apariencia física del establecimiento se convierte en el *proxy* de calidad más accesible cuando la información académica es costosa (Naik et al., 2017; Dubey et al., 2016). Si las familias más vulnerables eligen por apariencia en lugar de calidad, el sesgo perjudica exactamente a quienes el mecanismo intenta proteger (Hastings y Weinstein, 2008).

Este trabajo aborda dos preguntas: (i) ¿en qué medida la apariencia visual de los colegios distorsiona las preferencias?, y (ii) ¿puede un mecanismo de asignación corregir esa distorsión? Construimos señales visuales a partir de imágenes GSV procesadas con CLIP (Radford et al., 2021) y segmentación semántica, estimamos su efecto sobre la demanda mediante un modelo BLP (Berry, 1994; Conlon y Gortmaker, 2020), y evaluamos mecanismos estándar — BM, DA y SED-lex — junto con una regla aprendida de tipo WP sobre 99.890 familias de primer ingreso calibradas con la Encuesta Multipropósito 2021 (DANE, 2021).

Los resultados muestran que la seguridad percibida del colegio predice significativamente la demanda ($\hat{\beta} = +0,11$, $p < 0,01$), pero ningún mecanismo estándar corrige directamente el canal visual. Proponemos entonces una WP-Rule estable cuya prioridad de colegios combina ingreso y distancia, e incorpora una corrección visual calibrada para neutralizar la correlación entre ingreso y seguridad percibida asignada.

2. Datos y metodología

2.1 Datos de colegios y demanda

La unidad de análisis es el *establecimiento educativo* (no la sede). El directorio SED 2024 reporta 2.242 sedes agrupadas en establecimientos; al filtrar el sector oficial y agregar sedes a establecimiento—tomando la sede principal como punto geográfico representativo—, se obtienen inicialmente 408 establecimientos tras fusionar matrícula, demanda, puntajes Saber 11 (promedio 2020–2022–2023) y controles socioeconómicos de la Encuesta Multi-propósito 2021 por UPZ. Se excluyen 23 colegios rurales (Sumapaz y sedes aisladas sin cobertura EM2021) y 3 establecimientos sin cobertura GSV, resultando en **382 colegios oficiales urbanos** como muestra final. La exclusión de los rurales es sustantiva: un análisis preliminar con NMF sobre embeddings VGG19 (Simonyan y Zisserman, 2015) mostró que la totalidad de la señal visual capturada correspondía al contraste rural/urbano, no a variación dentro del entorno urbano.

Para la estimación estructural, se construye la cuota de mercado $s_j = D_j/M_t$ por localidad y se aplica la inversión de Berry (1994): $\delta_j = \ln s_j - \ln s_0$, donde s_0 es la outside option estimada por localidad. Los controles incluyen puntaje Saber 11, homicidios (log), distancia a SITP (log), competencia privada y condición técnica.

2.2 Pipeline de visión computacional

Se descargaron imágenes GSV de fachada para cada colegio oficial (10 headings por sede a $0^\circ, 36^\circ, \dots, 324^\circ$; 640×640 px, $\text{FOV} = 90^\circ$). Para cada establecimiento se procesan las 10 imágenes disponibles y se agregan los scores a nivel de establecimiento. Los 3 establecimientos sin GSV reciben imputación por vecindad en radio de 2 km.

Se emplean dos estrategias complementarias de extracción visual:

1. **CLIP ViT-B/32** (Radford et al., 2021): se computan 4 scores de percepción por establecimiento mediante prompts textuales calibrados (mantenimiento, vegetación percibida, modernidad y seguridad percibida). Cada score mide la similitud coseno entre el embedding de la imagen y el del prompt; a nivel de establecimiento se conserva el máximo observado entre las imágenes disponibles.
2. **Segmentación semántica (DeepLabV3+/Cityscapes)**: se extraen proporciones de píxeles de cada clase semántica por imagen. Tras análisis de colinealidad con las variables CLIP, se retienen 2 proporciones informativas: infraestructura vial y cerramiento.

2.3 Estimación de demanda

Berry OLS (segunda etapa). La utilidad media δ_j obtenida por inversión de Berry se descompone mediante OLS en cuatro especificaciones que añaden sucesivamente las señales visuales a los controles:

$$\delta_j = \beta_0 + \beta_{\text{seg}} \text{seg}_j + \beta_{\text{veg}} \text{veg}_j + \beta_{\text{vial}} \text{vial}_j + \beta_{\text{cerr}} \text{cerr}_j + \beta_q q_j + \mathbf{B}_C \mathbf{c}_j + \xi_j \quad (1)$$

donde seg_j y veg_j son scores CLIP de seguridad y vegetación percibidas; vial_j y cerr_j son proporciones Cityscapes de infraestructura vial y cerramiento; q_j mide calidad académica; y $\mathbf{c}_j$ agrupa controles de entorno escolar. Los resultados se presentan en la Tabla 1.

IV-BLP (primera etapa). Para capturar la heterogeneidad en preferencias por ingreso, se estima un modelo BLP con micro-momentos (Berry, 1994; Conlon y Gortmaker, 2020):

$$U_{ij} = \delta_j + \pi_1 y_i \text{seg}_j + \lambda_0 \log(1+d_{ij}) + \lambda_1 y_i \log(1+d_{ij}) + \varepsilon_{ij} \quad (2)$$

donde δ_j se recupera por contraction mapping y los parámetros no lineales $(\pi_1, \lambda_0, \lambda_1)$ se estiman por GMM. La calidad q_j se instrumenta con la calidad media de rivales ponderada por $1/d$ dentro de la localidad.

2.4 Familias y utilidades

La EM2021 registra hogares con hijos en colegio oficial en Bogotá; al expandir por FEX_C y conservar familias que buscan cupo de primer ingreso se obtienen 99.890 familias representativas, ubicadas en manzanas coherentes con su estrato y UPZ. A cada familia se le asigna un grupo SISBEN ($A-D$) a partir del ingreso per cápita. La utilidad sigue la ecuación (2) con parámetros del IV-BLP; las preferencias son el ranking de colegios accesibles por utilidad (d_{ij} Haversine). La capacidad de cada colegio es $\lfloor M_j/13 \rfloor$ (mínimo 5). En la evaluación de mecanismos, el universo efectivo está dado por los colegios que aparecen en las preferencias top-20 y tienen señal visual observada: 380 colegios y 113.857 cupos.

2.5 Mecanismos de asignación

Evaluamos cuatro mecanismos. Los tres primeros son estándar en la literatura de *school choice*; el cuarto es una contribución de este trabajo.

Boston (BM). Asignación inmediata con aceptaciones definitivas y prioridad geográfica. No es incentivo-compatible (IC): las familias pueden beneficiarse al no reportar sus preferencias verdaderas (Abdulkadiroğlu y Sönmez, 2003).

Deferred Acceptance (DA). Gale-Shapley estudiantil con aceptaciones provisionales y prioridad geográfica. IC, estable (cero blocking pairs) y óptimo entre matchings estables para los estudiantes (Abdulkadiroğlu y Sönmez, 2003).

SED-lex. DA con prioridad lexicográfica SISBEN ($A > B > C > D$) y desempate por proximidad geográfica. Réplica del mecanismo vigente de la SED (SED, 2025). Hereda las propiedades de DA (IC, estabilidad) y prioriza familias vulnerables.

Weighted Polytope Rule (WP). La regla WP sigue el marco de Narasimhan et al. (2016): aprende una función de bienestar lineal y la maximiza sobre el politopo de asignaciones estables. A diferencia de SED-lex, la prioridad de los colegios no es lexicográfica

en SISBEN. Definimos una prioridad continua que favorece menores ingresos y menor distancia, e incorpora una corrección visual:

$$P_{ij}^\theta = -\tilde{y}_i - \tilde{d}_{ij} - \theta \tilde{y}_i v_j, \quad (3)$$

donde $\tilde{y}_i$ es ingreso per cápita estandarizado, $\tilde{d}_{ij}$ es distancia estandarizada, y v_j es seguridad percibida. Valores mayores de P_{ij}^θ implican mayor prioridad del hogar i en el colegio j . El parámetro θ se calibra en mercados sintéticos Bogotá-like para que la correlación entre ingreso y seguridad percibida asignada sea cercana a cero.

Dada esta prioridad, la WP maximiza:

$$f_{WP}(\succ; W) \in \arg \max_{x \in \hat{\Omega}^{\text{st}}(\succ, P^\theta)} \sum_{ij} \lambda_{ij}(W) x_{ij}. \quad (4)$$

Usamos una parametrización parsimoniosa:

$$\lambda_{ij}(W) = aR_{ij} + bP_{ij}^\theta + d_v \tilde{y}_i v_j. \quad (5)$$

Aquí R_{ij} aumenta cuando la familia rankea mejor al colegio, P_{ij}^θ mide la prioridad ingreso–distancia ajustada por (3), y el término $d_v \tilde{y}_i v_j$ permite que el objetivo WP penalice asignaciones que vuelvan a correlacionar ingreso y seguridad percibida.

El StructSVM aprende $W = (a, b, d_v)$ a partir de mercados sintéticos. La estabilidad no se relaja: queda garantizada por las restricciones de $\hat{\Omega}^{\text{st}}(\succ, P^\theta)$, que incorporan cupos y ausencia de pares bloqueantes bajo la prioridad ingreso–distancia ajustada (Vande Vate, 1989). Como benchmarks incluimos WP_{baseline}, sin corrección visual en el objetivo ($d_v = 0$), y WP_{equal}, con pesos iguales sobre preferencias y prioridad.

En la aplicación a datos reales no resolvemos el LP completo de (4) sobre las 99.890 familias, porque el número de variables familia–colegio y restricciones de estabilidad crece al orden de millones aun usando listas top-20. En su lugar aplicamos la parte escalable de la regla aprendida: corremos DA con la prioridad calibrada P_{ij}^θ . Esta versión, que llamamos WP-priority, no reentrena el modelo y preserva estabilidad exacta bajo la prioridad ingreso–distancia–visual, pero debe interpretarse como la implementación a escala real de la prioridad WP, no como la solución del LP global de WP.

3. Resultados

3.1 Estimación de demanda

La Tabla 1 presenta los resultados de la segunda etapa (Berry OLS) y los parámetros heterogéneos del IV-BLP.

Tres hallazgos centrales. **Primero**, la seguridad percibida (CLIP) es la única señal visual estadísticamente significativa (+0,110, $p < 0,01$): los colegios que lucen más seguros atraen más demanda, independientemente de su calidad académica. **Segundo**, el puntaje Saber 11 tiene coeficiente *negativo* (−0,180): controlando por zona, las familias no eligen por resultados académicos. **Tercero**, el IV-BLP confirma heterogeneidad por ingreso: $\hat{\lambda}_1 = -0,094$ indica que la distancia penaliza más a familias de mayor ingreso, y $\hat{\pi}_1 = -0,028$ sugiere que familias de mayor ingreso responden marginalmente menos a la seguridad percibida. Los coeficientes lineales son robustos a la instrumentación.

Cuadro 1: Estimación de demanda escolar (382 colegios urbanos)

Variable	Berry OLS — δ_j				IV-BLP
	M0	M1	M2	M3	θ
<i>Señales visuales</i>					
Seg. percibida (CLIP)	—	0,108***	—	0,110***	
Veg. percibida (CLIP)	—	−0,001	—	−0,002	
Infra. vial (CS)	—	—	0,023	0,019	
Cerramiento (CS)	—	—	0,023	0,030	
<i>Calidad y controles</i>					
Saber 11 (q_j)	−0,183***	−0,183***	−0,181***	−0,180***	−0,184***
Homicidios (log)	−0,440***	−0,432***	−0,443***	−0,435***	−0,440***
Técnico	0,485***	0,441***	0,483***	0,439***	0,445***
Compet. privada	−0,443***	−0,420***	−0,443***	−0,418***	−0,417***
<i>Parámetros heterogéneos (BLP)</i>					
π_1 ($y_i \times \text{seg}$)					−0,028
λ_0 (distancia)					+0,024
λ_1 ($y_i \times \text{dist}$)					−0,094
R^2_{adj}	0,460	0,469	0,459	0,467	—
First-stage F					18,8

Nota. Variables estandarizadas (media 0, DE 1). *** $p < 0,01$. Berry OLS: variable dependiente $\delta_j = \ln s_j - \ln s_0$. IV-BLP: q_j instrumentado con calidad media de rivales ponderada por $1/d$ en la localidad. CS = Cityscapes.

3.2 WP-Rule

La WP-Rule se evalúa primero en mercados sintéticos *Bogotá-like*, donde es posible observar si una prioridad diseñada puede romper el canal visual sin perder estabilidad. La prioridad ingreso–distancia–visual se calibra para que la asignación estable no herede una correlación sistemática entre ingreso y seguridad percibida; luego el StructSVM aprende los pesos $W = (a, b, d_v)$ de la función objetivo.

En validación, los tres criterios WP entregan resultados prácticamente idénticos:

	$\text{corr}(y, v)$	$\text{corr}(y, q)$	$\bar{q}$	rank
WP _{learned}	−0,0083	0,0508	−0,0098	7,00
WP _{baseline}	−0,0083	0,0508	−0,0098	7,00
WP _{equal}	−0,0080	0,0511	−0,0098	7,00

La correlación ingreso–seguridad queda cerca de cero sin introducir pares bloqueantes. Además, la similitud entre WP_{learned}, WP_{baseline} y WP_{equal} muestra que la corrección proviene principalmente de la prioridad que define el conjunto estable, no de pequeñas diferencias en los pesos finales del objetivo.

Fuera de validación, la regla mantiene el mismo patrón: en mercados Bogotá-like de test se obtiene $\text{corr}(y, v) = 0,0129$ y $\text{corr}(y, q) = 0,1228$. En el escenario diagnóstico ortogonal ($\rho = 0$), donde seguridad percibida y calidad se generan sin correlación, la WP produce $\text{corr}(y, v) = 0,0288$ y $\text{corr}(y, q) = 0,0729$.

La robustez a distintos valores de $\rho = \text{corr}(v_j, q_j)$ refuerza esta lectura. Para WP_{learned},

$\text{corr}(y, v)$ pasa de 0,0011 cuando $\rho = 0$ a 0,0993 cuando $\rho = 1$, siempre con cero pares bloqueantes y acceso A/B cercano a 0,98–0,99. La conclusión de esta sección es que WP funciona como prueba de diseño: una prioridad estable, construida con ingreso, distancia y señal visual, puede contener el sorting visual en mercados controlados.

3.3 Comparación de mecanismos

Comparamos BM, DA, SED-lex y WP en dos ejercicios. El primero usa mercados sintéticos Bogotá-like; el segundo aplica los mecanismos a las preferencias y capacidades reales. En ambos casos, las diferencias provienen de la regla de prioridad y de si el mecanismo impone estabilidad.

Cuadro 2: Comparación de mecanismos en mercados sintéticos Bogotá-like

Mecanismo	$\text{corr}(y, v)$	$\text{corr}(y, q)$	$\bar{q}$	Rank	BP
BM	−0,033	−0,030	0,052	4,58	24,8
DA	0,002	−0,005	0,052	8,07	0,0
SED-lex	−0,077	0,129	0,052	5,51	0,0
WP _{learned}	0,018	0,078	0,052	6,91	0,0

Nota. Rank es la posición promedio del colegio asignado en la lista de preferencias del hogar; BP reporta pares bloqueantes promedio por mercado.

En el escenario sintético, BM obtiene el mejor rank promedio, pero genera pares bloqueantes. DA, SED-lex y WP son estables. SED-lex mejora el rank frente a DA, pero aumenta la correlación ingreso–calidad; esto no contradice su prioridad por vulnerabilidad, porque la regla respeta las preferencias declaradas. Si esas preferencias están mediadas por seguridad percibida, distancia u oferta local, priorizar a hogares vulnerables dentro de sus opciones elegidas no necesariamente corrige el sorting agregado hacia calidad académica. WP_{learned} mantiene estabilidad y contiene la correlación ingreso–seguridad, con un costo de rank frente a BM y SED-lex.

En datos reales, la lectura cambia. El universo efectivo contiene 99.890 familias de primer ingreso, 380 colegios presentes en las preferencias top-20 y 113.857 cupos. Todos los mecanismos asignan 96.022 familias; por tanto, la comparación relevante no es el volumen total asignado, sino el sorting por ingreso, calidad y seguridad percibida.

Cuadro 3: Comparación de mecanismos en datos reales

Mecanismo	$\text{corr}(y, v)$	$\text{corr}(y, q)$	$\bar{q}$	Rank	BP
BM	0,0188	0,1067	256,67	1,83	4.148
DA	0,0242	0,1329	256,68	2,63	0
SED-lex	0,0016	0,0979	256,67	1,91	0
WP-priority	0,0181	0,1043	256,67	1,92	0

Nota. WP-priority aplica la prioridad ingreso–distancia–visual calibrada en la WP-Rule y corre DA sobre datos reales; no resuelve el LP global de WP a escala completa.

SED-lex es el mecanismo que más neutraliza el canal visual: $\text{corr}(y, v) = 0,0016$. WP-priority mejora frente a DA y mantiene estabilidad exacta, pero no supera a SED-lex. La diferencia con el ejercicio sintético es informativa: con preferencias reales restringidas por localidad, la prioridad lexicográfica por vulnerabilidad y el desempate geográfico ya corrigen

casi por completo el sorting ingreso–seguridad. WP-priority queda como una alternativa estable y continua, pero el mecanismo vigente contiene una palanca redistributiva más fuerte en este contexto.

4. Conclusiones y limitaciones

Este trabajo muestra que las señales visuales del entorno escolar contienen información conductual relevante: la seguridad percibida medida con CLIP predice sobredemanda aun controlando por calidad académica y entorno urbano ($\hat{\beta}_{\text{seg}} \approx 0,11$, $p < 0,01$). Al mismo tiempo, el puntaje Saber 11 no aumenta la demanda condicional. La implicación es directa: antes de la matrícula, las familias parecen responder más a señales visibles y accesibles que a medidas académicas difíciles de observar.

La segunda contribución es de diseño de mecanismos. En mercados sintéticos, la WP-Rule muestra que una prioridad ingreso–distancia–visual puede reducir el sorting ingreso–seguridad manteniendo estabilidad. Sin embargo, al aplicar los mecanismos sobre datos reales, SED-lex es el mecanismo que mejor neutraliza el canal visual: $\text{corr}(y, v) = 0,0016$, prácticamente cero. También mejora la equidad en calidad frente a BM y DA y mantiene un rank promedio cercano al de WP-priority. La versión escalable de WP mejora frente a DA, pero no supera a SED-lex.

La lectura central es que, en Bogotá, la prioridad importa más que la forma fina del objetivo. Cuando las preferencias ya están restringidas por localidad, una prioridad lexicográfica por vulnerabilidad con desempate geográfico redistribuye el acceso dentro de los conjuntos de opciones locales y corrige casi por completo el sorting ingreso–seguridad. WP sigue siendo útil como ejercicio de diseño: muestra cómo construir prioridades estables orientadas a una métrica de equidad específica. Pero los datos reales sugieren que el sistema vigente ya contiene una palanca potente de corrección visual.

Limitaciones. (i) La demanda SED no está desagregada por localidad de origen del solicitante; por tanto, las cuotas de mercado se construyen suponiendo que la demanda de cada colegio proviene de su localidad. (ii) La estimación BLP opera con 19 mercados, lo que limita las propiedades asintóticas de los errores estándar agrupados. (iii) El sorting residencial puede sesgar la penalización estimada por distancia: familias de mayor ingreso pueden vivir cerca de colegios de mayor calidad y mejores entornos urbanos. (iv) En datos reales aplicamos WP-priority, no el LP global de WP, por razones de escala computacional; por tanto, los resultados reales evalúan la prioridad aprendida, no todo el politopo estable.

Implicaciones de política. El resultado de política no es que el mecanismo vigente falle, sino que cumple una función correctiva importante. Las señales visuales influyen en la demanda, pero SED-lex neutraliza casi por completo su transmisión a la asignación final. Por tanto, una reforma orientada a equidad debería preservar la prioridad por vulnerabilidad y el desempate geográfico. Cualquier intervención sobre apariencia o infraestructura visual debería complementarse con información activa y verificable sobre calidad académica (Hastings y Weinstein, 2008; Allende et al., 2019), para que las preferencias familiares no dependan únicamente de señales visibles.

Referencias

- Abdulkadiroğlu, A. y Sönmez, T. School choice: A mechanism design approach. *American Economic Review*, 93(3):729–747, 2003.
- Allende, C., Gallego, F. A., y Neilson, C. A. Approximating the equilibrium effects of informed school choice. *The Review of Economic Studies*, revise and resubmit, 2019.
- Berry, S. Estimating discrete-choice models of product differentiation. *RAND Journal of Economics*, 25(2):242–262, 1994.
- Conlon, C. y Gortmaker, J. Best practices for differentiated products demand estimation with PyBLP. *RAND Journal of Economics*, 51(4):1108–1161, 2020.
- Departamento Administrativo Nacional de Estadística (DANE). *Encuesta Multipropósito Bogotá 2021 (EM2021)*. DANE – Secretaría Distrital de Planeación, 2021.
- Departamento Administrativo Nacional de Estadística (DANE). *Boletín técnico: Pobreza Monetaria Colombia 2024*. DANE, 2024.
- Departamento Administrativo Nacional de Estadística (DANE). *Comunicado de prensa: Clases Sociales 2024*. DANE, 2024.
- Radford, A., Kim, J. W., Hallacy, C., et al. Learning transferable visual models from natural language supervision. En *ICML 2021*, pp. 8748–8763. PMLR, 2021.
- Dubey, A., Naik, N., Parikh, D., Raskar, R., y Hidalgo, C. A. Deep learning the city: Quantifying urban perception at a global scale. En *ECCV 2016*, pp. 196–212. Springer, 2016.
- Gale, D. y Shapley, L. S. College admissions and the stability of marriage. *The American Mathematical Monthly*, 69(1):9–15, 1962.
- Hastings, J. S., Kane, T. J., y Staiger, D. O. Heterogeneous preferences and the efficacy of public school choice (NBER WP 12145). National Bureau of Economic Research, 2009.
- Hastings, J. S. y Weinstein, J. M. Information, school choice, and academic achievement. *Quarterly Journal of Economics*, 123(4):1373–1414, 2008.
- Lee, D. D. y Seung, H. S. Algorithms for non-negative matrix factorization. En *NeurIPS 2000*, pp. 556–562. MIT Press, 2001.
- Naik, N., Raskar, R., y Hidalgo, C. A. Computer vision uncovers predictors of physical urban change. *PNAS*, 114(29):7571–7576, 2017.
- Roth, A. E. The evolution of the labor market for medical interns and residents: a case study in game theory. *Journal of Political Economy*, 92(6):991–1016, 1984.
- Secretaría de Educación del Distrito (SED). *I Informe Caracterización Sector Educativo Bogotá D.C. 2023*. Alcaldía Mayor de Bogotá, 2023.
- Secretaría de Educación del Distrito (SED). *Resolución 1587 de 2025: gestión de la cobertura educativa para las vigencias 2025 y 2026*. SED, 2025.

- Narasimhan, H., Agarwal, S., y Parkes, D. C. Automated mechanism design without money via machine learning. En *IJCAI 2016*, pp. 433–439. AAAI Press, 2016.
- Simonyan, K. y Zisserman, A. Very deep convolutional networks for large-scale image recognition. En *ICLR 2015*, 2015.
- Vande Vate, J. H. Linear programming brings marital bliss. *Operations Research Letters*, 8(3):147–153, 1989.