

Señales visuales, estimación de demanda y diseño de mecanismos en la asignación de cupos escolares de Bogotá

Bautista, David.

Fuentes, Jhoan.

Melo, Jonathan.

2026

1. Introducción

El sistema de educación pública de Bogotá agrupa 413 instituciones en 740 sedes distribuidas en 20 localidades, con más del 40 % de las nuevas solicitudes concentradas en Kennedy, Bosa y Ciudad Bolívar (SED, 2023). La asignación está regulada por una prioridad que combina vulnerabilidad socioeconómica y proximidad geográfica (SED, 2025), formalizable como Deferred Acceptance (DA) con prioridad lexicográfica (Gale y Shapley, 1962). Sin embargo, el mecanismo opera sobre preferencias que pueden estar sesgadas: cuando la información académica es costosa, la apariencia física del colegio puede funcionar como *proxy* visible de calidad (Hastings et al., 2009; Hastings y Weinstein, 2008; Naik et al., 2017; Dubey et al., 2016).

Este trabajo conecta dos literaturas que usualmente avanzan por separado. La literatura de *school choice* estudia cómo las reglas de prioridad y los mecanismos afectan estabilidad, incentivos y equidad (Abdulkadiroğlu y Sönmez, 2003). La literatura de visión computacional y percepción urbana muestra que señales visuales del entorno predicen valoraciones y decisiones espaciales (Naik et al., 2017; Dubey et al., 2016). La pregunta abierta es si esas señales visuales distorsionan la demanda escolar y si una regla de asignación puede contener esa distorsión sin sacrificar estabilidad.

Para responderla, construimos medidas visuales de colegios oficiales urbanos de Bogotá usando imágenes de Google Street View (GSV) procesadas con CLIP (Radford et al., 2021) y segmentación semántica. Estimamos su efecto sobre la demanda mediante Berry IV e IV-BLP con micro-momentos (Berry, 1994; Conlon y Gortmaker, 2020), y usamos las preferencias estimadas para evaluar Boston mechanism (BM), DA, SED-lex y una prioridad aprendida en mercados sintéticos. La aplicación real considera 99.890 familias de primer ingreso y 380 colegios con señal visual observada.

Encontramos que la seguridad percibida predice significativamente la demanda ($\hat{\beta} \approx 0,11$), mientras que la calidad académica no aumenta la demanda condicional. En el laboratorio sintético, la regla WP muestra que una prioridad ingreso–distancia–visual puede reducir el sorting ingreso–seguridad manteniendo estabilidad. En datos reales, sin embargo, SED-lex neutraliza casi por completo el canal visual. La contribución central es mostrar que el diseño de prioridades, más que la forma fina del objetivo, es la palanca clave para contener sesgos visuales en la asignación escolar.

2. Datos y metodología

2.1 Datos de colegios y demanda

La unidad de análisis es el *establecimiento educativo*. A partir del directorio SED 2024, filtramos el sector oficial, agregamos sedes a establecimiento usando la sede principal como punto geográfico, y fusionamos matrícula, demanda, puntajes Saber 11 (promedio 2020–2022–2023), controles socioeconómicos de la EM2021 por UPZ y señales visuales. La muestra inicial contiene 408 establecimientos; excluimos 23 colegios rurales y 3 establecimientos sin cobertura GSV, para una muestra final de **382 colegios oficiales urbanos**. La exclusión rural evita que la señal visual capture solo el contraste rural/urbano, como sugería un análisis preliminar con NMF sobre embeddings VGG19 (Simonyan y Zisserman, 2015).

Para la estimación de demanda, construimos cuotas de mercado por localidad, $s_j = D_j/M_t$, y aplicamos la inversión de Berry (1994): $\delta_j = \ln s_j - \ln s_0$, donde s_0 es la outside option local. Los controles incluyen Saber 11, homicidios (log), distancia al Sistema Integrado de Transporte Público - SITP (log), competencia privada y condición técnica.

2.2 Pipeline de visión computacional

Para cada colegio oficial descargamos imágenes GSV de fachada en 10 ángulos ($0^\circ, 36^\circ, \dots, 324^\circ$; 640×640 px, FOV=90°). Las señales visuales se extraen con dos métodos. Primero, CLIP ViT-B/32 (Radford et al., 2021) calcula similitudes coseno entre cada imagen y prompts calibrados de mantenimiento del entorno, vegetación, modernidad del establecimiento y seguridad percibida; a nivel de establecimiento conservamos el máximo observado entre imágenes. Segundo, DeepLabV3+ (Chen et al., 2018), preentrenado en Cityscapes (Cordts et al., 2016), produce proporciones de clases semánticas por imagen; tras revisar colinealidad con CLIP, retenemos infraestructura vial y cerramiento.

2.3 Estimación de demanda

Modelo agregado: Berry IV. La utilidad media δ_j obtenida por inversión de Berry se estima por 2SLS sobre señales visuales y controles:

$$\delta_j = \beta_0 + \beta_{\text{seg}} \text{seg}_j + \beta_{\text{veg}} \text{veg}_j + \beta_{\text{vial}} \text{vial}_j + \beta_{\text{cerr}} \text{cerr}_j + \beta_q q_j + \mathbf{B}_C \mathbf{c}_j + \xi_j, \quad (1)$$

donde seg_j y veg_j son scores CLIP; vial_j y cerr_j son proporciones Cityscapes; q_j es calidad académica y $\mathbf{c}_j$ agrupa controles de entorno escolar.

Modelo estructural con heterogeneidad: IV-BLP. Para construir preferencias individuales estimamos un BLP con micro-momentos (Berry, 1994; Conlon y Gortmaker, 2020):

$$U_{ij} = \delta_j + \pi_1 y_i \text{seg}_j + \lambda_0 \log(1+d_{ij}) + \lambda_1 y_i \log(1+d_{ij}) + \varepsilon_{ij}. \quad (2)$$

Como no observamos elecciones hogar–colegio individuales, disciplinamos $\psi = (\pi_1, \lambda_0, \lambda_1)$ con dos micro-momentos proxy a nivel de colegio. Para cada colegio j , el modelo predice el ingreso medio y la distancia media de sus demandantes:

$$m_j^{y, \text{pred}}(\psi) = \frac{\sum_i y_i p_{ij}(\psi)}{\sum_i p_{ij}(\psi)}, \quad m_j^{d, \text{pred}}(\psi) = \frac{\sum_i d_{ij} p_{ij}(\psi)}{\sum_i p_{ij}(\psi)}. \quad (3)$$

Estos momentos se emparejan con proxies contruïdos a partir de EM2021:

$$m_j^{y,proxy} = \frac{\sum_i y_i / d_{ij}}{\sum_i 1 / d_{ij}}, \quad m_j^{d,proxy} = \frac{\sum_i \omega_i d_{ij}}{\sum_i \omega_i},$$

donde ω_i son factores de expansión. El componente micro del GMM minimiza:

$$Q^{micro}(\psi) = \sum_j \left(m_j^{y,pred}(\psi) - m_j^{y,proxy} \right)^2 + \sum_j \left(m_j^{d,pred}(\psi) - m_j^{d,proxy} \right)^2. \quad (4)$$

Así, la heterogeneidad por ingreso se identifica usando dos restricciones observables aproximadas: qué ingreso de hogares queda expuesto a cada colegio y qué distancia efectiva enfrenta su demanda potencial. La calidad q_j se instrumenta con la calidad media de rivales ponderada por $1/d$ dentro de la localidad tanto en Berry IV como en BLP.

2.4 Familias y utilidades

La EM2021 permite construir 99.890 familias representativas que buscan cupo de primer ingreso, tras expandir por FEX_C y ubicar hogares en manzanas coherentes con su estrato y UPZ. A cada familia se le asigna un grupo SISBEN ($A-D$) aproximado a partir del ingreso per cápita. Las preferencias se obtienen ordenando los colegios accesibles por la utilidad de (2), usando distancias Haversine. La capacidad escolar se aproxima como $\lfloor M_j/13 \rfloor$ (mínimo 5). En mecanismos reales, el universo efectivo queda dado por las listas top-20 con señal visual observada: 380 colegios y 113.857 cupos.

Para entrenar y validar la WP-rule usamos mercados sintéticos calibrados a Bogotá. Estos preservan las distribuciones marginales observadas de ingreso, SISBEN, calidad académica, seguridad percibida, capacidad y la correlación empírica entre calidad y seguridad visual. A diferencia de los datos reales, la localización de hogares y colegios se genera aleatoriamente en un plano unitario, por lo que el ingreso no queda correlacionado con la ubicación. Así, el ejercicio sintético elimina deliberadamente la segregación residencial para aislar el efecto del diseño de prioridades sobre el canal ingreso–seguridad; la aplicación real reintroduce geografía, restricciones de localidad y capacidades observadas.

2.5 Mecanismos de asignación

Evaluamos BM, DA, SED-lex y una regla aprendida basada en WP. BM asigna de forma inmediata con prioridad geográfica, no es estable ni incentivo-compatible; DA usa aceptaciones provisionales, es estable e incentivo-compatible para estudiantes (Abdulkadiroğlu y Sönmez, 2003); SED-lex replica la regla vigente de la SED: DA con prioridad lexicográfica SISBEN ($A > B > C > D$) — aproximada a partir de ingresos reportados en EM2021 — y desempate geográfico (SED, 2025).

La regla aprendida sigue el marco WP de Narasimhan et al. (2016): el diseñador escoge una asignación dentro del politopo estable $\hat{\Omega}^{st}(\succ, P)$ (Vande Vate, 1989). Definimos una prioridad continua que favorece menores ingresos, menor distancia y corrige el canal visual:

$$P_{ij}^\theta = -\tilde{y}_i - \tilde{d}_{ij} - \theta \tilde{y}_i v_j, \quad (5)$$

donde $\tilde{y}_i$ es ingreso estandarizado, $\tilde{d}_{ij}$ es distancia estandarizada y v_j es seguridad percibida. El parámetro θ se calibra en mercados sintéticos para que la correlación entre ingreso y seguridad percibida asignada sea cercana a cero.

Dada esta prioridad, WP resuelve:

$$f_{WP}(\succ; W) \in \arg \max_{x \in \hat{\Omega}^{\text{st}}(\succ, P^\theta)} \sum_{ij} \lambda_{ij}(W) x_{ij}. \quad (6)$$

Usamos una parametrización parsimoniosa:

$$\lambda_{ij}(W) = aR_{ij} + bP_{ij}^\theta + d_v \tilde{y}_i v_j. \quad (7)$$

El StructSVM aprende $W = (a, b, d_v)$ en mercados sintéticos; como benchmarks usamos WP_{baseline} ($d_v = 0$) y WP_{equal} . La estabilidad no se relaja: está impuesta por el politopo estable bajo P^θ .

En datos reales no resolvemos el LP global de WP sobre 99.890 familias por escala computacional. Implementamos la versión escalable $DA-P^{\theta*}$: DA con la prioridad calibrada. Esta asignación preserva estabilidad exacta bajo la prioridad ingreso–distancia–visual, pero evalúa la prioridad aprendida, no la solución completa del LP de WP.

3. Resultados

3.1 Estimación de demanda

La Tabla 1 presenta los resultados de Berry IV y los parámetros heterogéneos del IV-BLP.

Cuadro 1: Estimación de demanda escolar (382 colegios urbanos)

Variable	M0	Berry IV — δ_j		M3	IV-BLP
		M1	M2		
<i>Señales visuales</i>					
Seg. percibida (CLIP)	—	0,107***	—	0,108***	0,112**
Veg. percibida (CLIP)	—	0,016	—	0,015	
Infra. vial (CS)	—	—	0,019	0,017	
Cerramiento (CS)	—	—	0,017	0,023	
<i>Calidad y controles</i>					
Saber 11 (q_j)	−0,279***	−0,281**	−0,275***	−0,278**	−0,184***
Homicidios (log)	−0,441***	−0,433***	−0,443***	−0,436***	−0,440***
Técnico	0,495***	0,453***	0,494***	0,451***	0,445***
Compet. privada	−0,394***	−0,405***	−0,393***	−0,405***	−0,417***
<i>Parámetros heterogéneos (BLP)</i>					
π_1 ($y_i \times \text{seg}$)					−0,028
λ_0 (distancia)					+0,024
λ_1 ($y_i \times \text{dist}$)					−0,094***
R_{adj}^2	0,448	0,456	0,447	0,455	—
First-stage F	47,2	44,6	45,6	43,0	18,8

Nota. Variables estandarizadas (media 0, DE 1). ** $p < 0,05$; *** $p < 0,01$. Berry IV: variable dependiente $\delta_j = \ln s_j - \ln s_0$. Berry IV e IV-BLP instrumentan q_j con calidad media de rivales ponderada por $1/d$ en la localidad. First-stage F reporta el instrumento excluido; IV-BLP reporta SE mediante Bootstrap. CS = Cityscapes.

La Tabla 1 deja tres resultados. Primero, la seguridad percibida es la única señal visual robusta: en Berry IV y en IV-BLP su coeficiente es positivo y significativo (0,108–0,112), lo que indica que colegios que lucen más seguros atraen más demanda condicional

a calidad y entorno. Segundo, Saber 11 entra con signo negativo ($-0,278$ en M3-IV): en estas preferencias reveladas, la demanda no se ordena por desempeño académico observable. Tercero, la heterogeneidad estimada por BLP aparece principalmente en distancia: $\hat{\lambda}_1 = -0,094$ sugiere que el costo de distancia varía con ingreso, mientras que $\hat{\pi}_1 = -0,028$ no es estadísticamente significativo. Esto impide afirmar que la sensibilidad a seguridad percibida difiera por ingreso; una explicación plausible es la segregación espacial, que hace que hogares de distinto ingreso enfrenten conjuntos de colegios parcialmente distintos.

3.2 WP-Rule

La WP-Rule se evalúa en mercados sintéticos calibrados a Bogotá para probar si una prioridad ingreso–distancia–visual puede contener el sorting ingreso–seguridad sin perder estabilidad. Primero calibramos $P_{ij}^{\theta^*}$ para que DA bajo esa prioridad produzca una correlación ingreso–seguridad cercana a cero; luego el StructSVM aprende los pesos $W = (a, b, d_v)$ de la función objetivo WP.

Los tres criterios WP son casi indistinguibles: WP_{learned} , WP_{baseline} y WP_{equal} entregan $\text{corr}(y, v) \approx -0,008$, $\text{corr}(y, q) \approx 0,051$ y rank promedio cercano a 7, sin pares bloqueantes. Esta similitud es informativa: en este diseño, la corrección proviene principalmente de la prioridad que define el conjunto estable, no de pequeñas diferencias en los pesos finales del objetivo.

La robustez confirma el patrón. En mercados de test con correlaciones reales se obtiene $\text{corr}(y, v) = 0,0129$ y $\text{corr}(y, q) = 0,1228$; en el escenario ortogonal ($\rho = 0$), la WP produce $\text{corr}(y, v) = 0,0288$. Al barrer $\rho = \text{corr}(v_j, q_j)$, WP_{learned} mantiene cero pares bloqueantes y acceso A/B cercano a 0,98–0,99. Así, WP funciona como laboratorio de diseño: permite aprender una prioridad estable orientada a reducir el canal visual en mercados controlados.

3.3 Comparación de mecanismos

Comparamos BM, DA, SED-lex y WP en dos ejercicios: mercados sintéticos calibrados a Bogotá y datos reales. En datos reales no resolvemos el LP completo de WP; aplicamos su versión escalable, $DA-P^{\theta^*}$, que inserta en DA la prioridad ingreso–distancia–visual calibrada en la WP-Rule.

Cuadro 2: Comparación de mecanismos en mercados sintéticos calibrados a Bogotá

Mecanismo	$\text{corr}(y, v)$	$\text{corr}(y, q)$	$\bar{q}$	Rank	Acc. A/B	BP
BM	$-0,033$	$-0,030$	0,052	4,58	85,9 %	24,8
DA	0,002	$-0,005$	0,052	8,07	86,2 %	0,0
SED-lex	$-0,077$	0,129	0,052	5,51	100,0 %	0,0
WP_{learned}	0,018	0,078	0,052	6,91	98,6 %	0,0

Nota. $\bar{q}$ se reporta en unidades estandarizadas. Acc. A/B es el porcentaje de familias SISBEN A/B asignadas.

En sintéticos, BM logra el mejor rank promedio, pero genera pares bloqueantes. DA, SED-lex y WP son estables. SED-lex mejora el rank frente a DA, pero aumenta $\text{corr}(y, q)$: al respetar preferencias declaradas, priorizar hogares vulnerables no garantiza mejorar calidad académica si sus opciones están mediadas por seguridad percibida, distancia u

oferta local. WP_{learned} mantiene estabilidad y contiene mejor el canal ingreso–seguridad, con costo en rank frente a BM y SED-lex.

En datos reales, todos los mecanismos asignan 96.022 familias sobre un universo efectivo de 99.890 hogares, 380 colegios y 113.857 cupos; por tanto, la comparación relevante es el sorting por ingreso, calidad y seguridad percibida.

Cuadro 3: Comparación de mecanismos en datos reales

Mecanismo	$\text{corr}(y, v)$	$\text{corr}(y, q)$	$\bar{q}$	Rank	Acc. A/B	BP
BM	0,0188	0,1067	−0,108	1,83	96,3 %	4.148
DA	0,0242	0,1329	−0,108	2,63	95,9 %	0
SED-lex	0,0016	0,0979	−0,108	1,91	100,0 %	0
DA- P^{θ^*}	0,0181	0,1043	−0,108	1,92	100,0 %	0

Nota. $\bar{q}$ se reporta en unidades estandarizadas sobre los 380 colegios efectivos; Acc. A/B es el porcentaje de familias SISBEN A/B asignadas. DA- P^{θ^*} aplica la prioridad ingreso–distancia–visual calibrada en la WP-Rule y corre DA sobre datos reales; no resuelve el LP global de WP a escala completa.

La lectura cambia en datos reales: SED-lex neutraliza casi por completo el canal visual ($\text{corr}(y, v) = 0,0016$), supera a DA- P^{θ^*} en esa métrica y mantiene estabilidad exacta. Esto sugiere que, con preferencias restringidas por localidad, la prioridad lexicográfica por vulnerabilidad y el desempate geográfico ya corrigen gran parte del sorting ingreso–seguridad. DA- P^{θ^*} queda como alternativa estable y continua, pero menos redistributiva que SED-lex en la geografía real de Bogotá.

4. Conclusiones y limitaciones

Este trabajo documenta que las señales visuales del entorno escolar contienen información conductual relevante: la seguridad percibida medida con CLIP predice demanda aun controlando por calidad académica y entorno urbano ($\hat{\beta}_{\text{seg}} \approx 0,11$), mientras que Saber 11 no aumenta la demanda condicional. Antes de la matrícula, las familias parecen responder más a señales visibles y accesibles que a medidas académicas difíciles de observar.

En diseño de mecanismos, WP muestra en mercados sintéticos que una prioridad ingreso–distancia–visual puede reducir el sorting ingreso–seguridad manteniendo estabilidad. Sin embargo, en datos reales SED-lex neutraliza casi por completo el canal visual y garantiza acceso A/B completo. La conclusión central es que, en Bogotá, la definición de las prioridades importa más que la forma funcional del objetivo: con preferencias restringidas por localidad, la prioridad lexicográfica por vulnerabilidad y el desempate geográfico ya redistribuyen el acceso dentro de conjuntos de elección locales. WP sigue siendo útil como laboratorio de diseño, pero la evidencia real sugiere que el mecanismo vigente contiene una palanca correctiva potente.

Limitaciones. (i) La demanda SED no está desagregada por localidad de origen del solicitante, por lo que las cuotas de mercado suponen que la demanda de cada colegio proviene de su localidad. (ii) El BLP opera con 19 mercados y micro-momentos proxy contruidos con EM2021, localidad/UPZ, ingreso y distancia, no con elecciones hogar–colegio observadas. (iii) El sorting residencial reduce la superposición entre conjuntos de elección de hogares de distinto ingreso; por tanto, π_1 puede combinar heterogeneidad

en preferencias con diferencias de oferta local y exposición visual. (iv) En datos reales aplicamos $DA-P^{\theta^*}$, no el LP global de WP; los resultados evalúan la prioridad aprendida, no todo el politopo estable.

Implicaciones de política. El resultado no es que el mecanismo vigente falle, sino que cumple una función correctiva importante. Una reforma orientada a equidad debería preservar la prioridad por vulnerabilidad y el desempate geográfico. A la vez, cualquier intervención sobre apariencia o infraestructura visual debería complementarse con información activa y verificable sobre calidad académica (Hastings y Weinstein, 2008; Allende et al., 2019), para que las preferencias familiares no dependan únicamente de señales visibles.

Referencias

- Abdulkadiroğlu, A. y Sönmez, T. School choice: A mechanism design approach. *American Economic Review*, 93(3):729–747, 2003.
- Allende, C., Gallego, F. A., y Neilson, C. A. Approximating the equilibrium effects of informed school choice. *The Review of Economic Studies*, revise and resubmit, 2019.
- Berry, S. Estimating discrete-choice models of product differentiation. *RAND Journal of Economics*, 25(2):242–262, 1994.
- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., y Adam, H. Encoder-decoder with atrous separable convolution for semantic image segmentation. En *ECCV 2018*, pp. 801–818, 2018.
- Conlon, C. y Gortmaker, J. Best practices for differentiated products demand estimation with PyBLP. *RAND Journal of Economics*, 51(4):1108–1161, 2020.
- Cordts, M., Omran, M., Ramos, S., Rehfeld, T., Enzweiler, M., Benenson, R., Franke, U., Roth, S., y Schiele, B. The Cityscapes dataset for semantic urban scene understanding. En *CVPR 2016*, pp. 3213–3223, 2016.
- Departamento Administrativo Nacional de Estadística (DANE). *Encuesta Multipropósito Bogotá 2021 (EM2021)*. DANE – Secretaría Distrital de Planeación, 2021.
- Departamento Administrativo Nacional de Estadística (DANE). *Boletín técnico: Pobreza Monetaria Colombia 2024*. DANE, 2024.
- Departamento Administrativo Nacional de Estadística (DANE). *Comunicado de prensa: Clases Sociales 2024*. DANE, 2024.
- Radford, A., Kim, J. W., Hallacy, C., et al. Learning transferable visual models from natural language supervision. En *ICML 2021*, pp. 8748–8763. PMLR, 2021.
- Dubey, A., Naik, N., Parikh, D., Raskar, R., y Hidalgo, C. A. Deep learning the city: Quantifying urban perception at a global scale. En *ECCV 2016*, pp. 196–212. Springer, 2016.
- Gale, D. y Shapley, L. S. College admissions and the stability of marriage. *The American Mathematical Monthly*, 69(1):9–15, 1962.
- Hastings, J. S., Kane, T. J., y Staiger, D. O. Heterogeneous preferences and the efficacy of public school choice (NBER WP 12145). National Bureau of Economic Research, 2009.
- Hastings, J. S. y Weinstein, J. M. Information, school choice, and academic achievement. *Quarterly Journal of Economics*, 123(4):1373–1414, 2008.
- Lee, D. D. y Seung, H. S. Algorithms for non-negative matrix factorization. En *NeurIPS 2000*, pp. 556–562. MIT Press, 2001.
- Naik, N., Raskar, R., y Hidalgo, C. A. Computer vision uncovers predictors of physical urban change. *PNAS*, 114(29):7571–7576, 2017.

- Roth, A. E. The evolution of the labor market for medical interns and residents: a case study in game theory. *Journal of Political Economy*, 92(6):991–1016, 1984.
- Secretaría de Educación del Distrito (SED). *I Informe Caracterización Sector Educativo Bogotá D.C. 2023*. Alcaldía Mayor de Bogotá, 2023.
- Secretaría de Educación del Distrito (SED). *Resolución 1587 de 2025: gestión de la cobertura educativa para las vigencias 2025 y 2026*. SED, 2025.
- Narasimhan, H., Agarwal, S., y Parkes, D. C. Automated mechanism design without money via machine learning. En *IJCAI 2016*, pp. 433–439. AAAI Press, 2016.
- Simonyan, K. y Zisserman, A. Very deep convolutional networks for large-scale image recognition. En *ICLR 2015*, 2015.
- Vande Vate, J. H. Linear programming brings marital bliss. *Operations Research Letters*, 8(3):147–153, 1989.